

Processamento Digital de Imagem

Problema de Detecção Facial utilizando RCNN

Rodolfo Labiapari Mansur Guimarães

rodolfolabiapari@decom.ufop.br

Lattes: <http://goo.gl/MZv4Dc>

Departamento de Computação – Universidade Federal de Ouro Preto
Ouro Preto - MG – Brasil

Última Atualização: 28 de março de 2017.

Sumário

- 1 Introdução
 - Apresentação
 - Justificativa
- 2 Referencial Teórico
 - Rede Neural Convolucional
- 3 Desenvolvimento
 - Data Set
 - Treino, Teste e Validação
 - Configurações da API neon
- 4 Experimentos
- 5 Resultados
- 6 Conclusão
 - Trabalhos Futuros

Sumário

- 1 Introdução
 - Apresentação
 - Justificativa
- 2 Referencial Teórico
 - Rede Neural Convolucional
- 3 Desenvolvimento
 - Data Set
 - Treino, Teste e Validação
 - Configurações da API neon
- 4 Experimentos
- 5 Resultados
- 6 Conclusão
 - Trabalhos Futuros

Apresentação

- Pesquisas recentemente buscam focar em **detecção de face** em ambientes onde existe [Garcia and Delakis 2004]
 - **Maior complexidade;**
 - Sem perder sua **eficiência.**
- As maiores dificuldades atuais são
 - Larga variações de visualização de faces humanas em fundos não-padronizados; e também
 - A procura espacial onde cada face pode estar posicionada em diferentes posições e tamanhos [Haoxiang and Lin 2015].

Sumário

- 1 Introdução
 - Apresentação
 - **Justificativa**
- 2 Referencial Teórico
 - Rede Neural Convolucional
- 3 Desenvolvimento
 - Data Set
 - Treino, Teste e Validação
 - Configurações da API neon
- 4 Experimentos
- 5 Resultados
- 6 Conclusão
 - Trabalhos Futuros

- Sistemas computacionais **anteriores à redes neurais** possuíam características bastante **ineficientes** para imagens que tinham como propriedade fundos não-padronizados [Garcia and Delakis 2004].
- Sucesso de algoritmos que utilizam técnicas como a *convolutional neural network* (CNN) [LeCun 1989]
[Le Cun Jackel, B. Boser, J. S. Denker, D. Henderson, R. E. Howard, W. Hubbard et al. [LeCun et al. 1998] [Haoxiang and Lin 2015].

Sumário

- 1 Introdução
 - Apresentação
 - Justificativa
- 2 Referencial Teórico
 - Rede Neural Convolucional
- 3 Desenvolvimento
 - Data Set
 - Treino, Teste e Validação
 - Configurações da API neon
- 4 Experimentos
- 5 Resultados
- 6 Conclusão
 - Trabalhos Futuros

Sumário

- 1 Introdução
 - Apresentação
 - Justificativa
- 2 Referencial Teórico
 - Rede Neural Convolucional
- 3 Desenvolvimento
 - Data Set
 - Treino, Teste e Validação
 - Configurações da API neon
- 4 Experimentos
- 5 Resultados
- 6 Conclusão
 - Trabalhos Futuros

Extração do Mapa de Características - I




Figura 1: Visão geral do procedimento de detecção de objetos utilizando uma rede neural convolucional.

Extração do Mapa de Características - II




Figura 2: Procedimento inicial da rede neural. Chamado Mapa de Características.

- **Subsampling** utiliza o algoritmo de *max_pooling*
 - Reduz o tamanho de amostras a ser processada [Giusti et al. 2013].

Extração do Mapa de Características - III

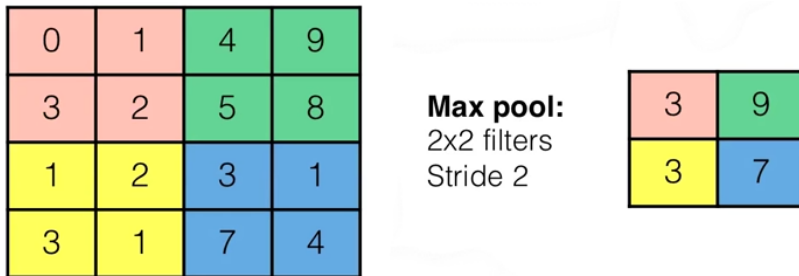


Figura 3: O processo de seleção de melhores resultados. Procedimento executado pela função `max_pooling` no *subsampling* do mapa de características.

Visão Geral da Rede Neural Convolucional

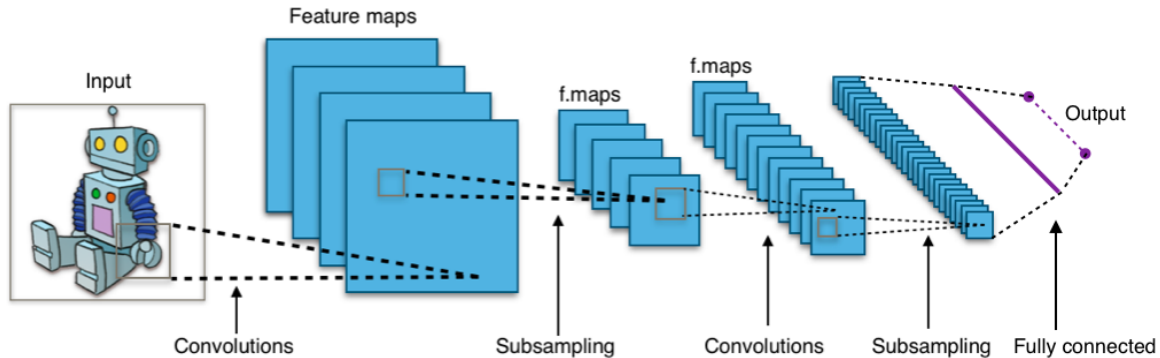


Figura 5: Arquitetura de reconhecimento de padrão *convolutional neural network* final após todos os processos, utilizando dois mapas de características em sequência.

Sumário

- 1 Introdução
 - Apresentação
 - Justificativa
- 2 Referencial Teórico
 - Rede Neural Convolucional
- 3 Desenvolvimento
 - Data Set
 - Treino, Teste e Validação
 - Configurações da API neon
- 4 Experimentos
- 5 Resultados
- 6 Conclusão
 - Trabalhos Futuros

Sumário

- 1 Introdução
 - Apresentação
 - Justificativa
- 2 Referencial Teórico
 - Rede Neural Convolucional
- 3 Desenvolvimento
 - **Data Set**
 - Treino, Teste e Validação
 - Configurações da API neon
- 4 Experimentos
- 5 Resultados
- 6 Conclusão
 - Trabalhos Futuros

Data Set - Faces94

- Disponível em <http://cswww.essex.ac.uk/mv/allfaces/faces94.html>.
- Propriedades:
 - Distância fixa da câmera;
 - Solicitados para que falem enquanto as fotos foram tiradas;
 - Imagens coloridas possuem plano de fundo verde;
 - Variações naturais de rotação, movimento e posição
 - Não possui variação de luminosidade.
- Total de 153 indivíduos, com imagens de resolução fixa no valor de 180×200 .



(a) Face 1



(b) Face 2



(c) Face 1
Cortada



(d) Face 2
Cortada

Figura 6: As respectivas faces já processadas e prontas para treino.

Data Set - FDDB





Figura 7: Exemplo de identificação de rosto especificado pelo *data set* disponibilizado pela Universidade de Massachusetts Amherst.



(a) Não-face
1



(b) Não-face
2



(c) Não-face
3

Figura 8: Algumas imagens recortadas para treino de não-faces.

Sumário

- 1 Introdução
 - Apresentação
 - Justificativa
- 2 Referencial Teórico
 - Rede Neural Convolucional
- 3 Desenvolvimento
 - Data Set
 - **Treino, Teste e Validação**
 - Configurações da API neon
- 4 Experimentos
- 5 Resultados
- 6 Conclusão
 - Trabalhos Futuros

Treino, Teste e Validação

Treino:

- Fddb-fold-01-ellipseList.txt
- Fddb-fold-02-ellipseList.txt
- Fddb-fold-03-ellipseList.txt
- Fddb-fold-04-ellipseList.txt

Teste:

- Fddb-fold-05-ellipseList.txt
- Fddb-fold-06-ellipseList.txt
- Fddb-fold-07-ellipseList.txt
- Fddb-fold-08-ellipseList.txt

Avaliação:

- Fddb-fold-09-ellipseList.txt
- Fddb-fold-10-ellipseList.txt

Sumário

- 1 Introdução
 - Apresentação
 - Justificativa
- 2 Referencial Teórico
 - Rede Neural Convolucional
- 3 Desenvolvimento
 - Data Set
 - Treino, Teste e Validação
 - Configurações da API neon
- 4 Experimentos
- 5 Resultados
- 6 Conclusão
 - Trabalhos Futuros

Configurações da API *neon*

- Camadas utilizadas na arquitetura da rede:

- **Convolution:** fshape=(5, 5, 4);
- **Pooling:** fshape=(2, 2);
- **Convolution:** fshape=(3, 3, 14);
- **Pooling:** fshape=(2, 2);
- **Affine:** nout=14;
- **Affine:** nout=2.

- As configurações utilizadas para a realização dos testes foram:

- **Batch size:** 512;
- **Numbers of epoch:** 1250;
- **Size of image (altura e largura):** 36;
- **Learning Rate:** 0.01
- **Momentum:** 0.9;
- **Format files:** .jpg;
- **Type of datas:** inteiro não sinalizado de 8-bits.

Configurações da API *neon*




Figura 9: Exemplo prático do processo dos mapas de características [Garcia and Delakis 2004].

Sumário

- 1 Introdução
 - Apresentação
 - Justificativa
- 2 Referencial Teórico
 - Rede Neural Convolucional
- 3 Desenvolvimento
 - Data Set
 - Treino, Teste e Validação
 - Configurações da API neon
- 4 Experimentos
- 5 Resultados
- 6 Conclusão
 - Trabalhos Futuros

Experimentos

- Adaptou-se para o reconhecimento de regiões, também chamado de *Region-based Convolutional Neural Network* (RCNN).
- Foi feito um processamento de geração de regiões que:
 - Pega a imagem original a ser avaliada;
 - Recorta-a em várias regiões de vários tamanhos diferentes;
 - Redimensiona-as para o formato padrão de entrada da rede neural.

Sumário

- 1 Introdução
 - Apresentação
 - Justificativa
- 2 Referencial Teórico
 - Rede Neural Convolucional
- 3 Desenvolvimento
 - Data Set
 - Treino, Teste e Validação
 - Configurações da API neon
- 4 Experimentos
- 5 Resultados
- 6 Conclusão
 - Trabalhos Futuros

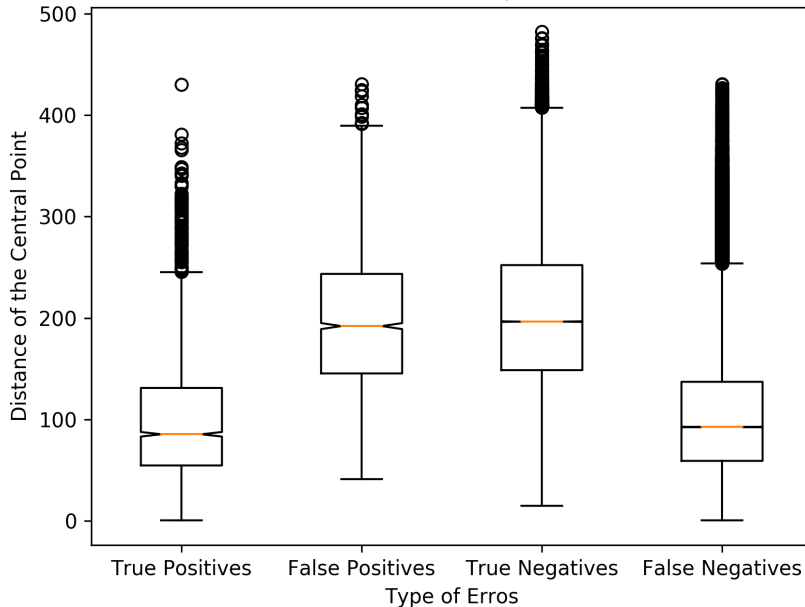
Resultados

Tabela 1: Valores totais e percentuais de cada tipo de erro dos *data sets* de validação.


	Numbers	%	Numbers	%
<i>True Positives</i>	2995	55,391	2801	51,038
<i>False Positives</i>	2412	44,608	2687	48,961
<i>True Negatives</i>	239.142	49,694	239.347	54,662
<i>False Negatives</i>	242.078	50,305	198.515	45,337
Total Regions	486.627	100	443.350	100


- Total de 929.977 regiões.
- Cerca de 50% de acerto em suas decisões.

Distance Graph 9



Distance Graph 10





Sumário

- 1 Introdução
 - Apresentação
 - Justificativa
- 2 Referencial Teórico
 - Rede Neural Convolucional
- 3 Desenvolvimento
 - Data Set
 - Treino, Teste e Validação
 - Configurações da API neon
- 4 Experimentos
- 5 Resultados
- 6 Conclusão
 - Trabalhos Futuros

Conclusão

- Conhecimento em teoria de inteligência artificial a configuração da rede e obtenção de resultados mais promissores.
- Conhecimento em teoria convolucional de imagens para adequar parâmetros para cada tipo de solução requisitada.
- Imagens e máscaras de pequeno porte dão resultados bons [Garcia and Delakis 2004].

Sumário

- 1 Introdução
 - Apresentação
 - Justificativa
- 2 Referencial Teórico
 - Rede Neural Convolucional
- 3 Desenvolvimento
 - Data Set
 - Treino, Teste e Validação
 - Configurações da API neon
- 4 Experimentos
- 5 Resultados
- 6 Conclusão
 - Trabalhos Futuros

Conclusão - Trabalhos Futuros

- Modificar o *data set* de faces.
- Realizar um filtro nas imagens do *data set* *FDDB*.
- Alterar o parâmetro de aprendizagem.
- Melhoria nas imagens de saída.
- Alterar a forma de saída da rede neural.

Processamento Digital de Imagem

Problema de Detecção Facial utilizando RCNN

Rodolfo Labiapari Mansur Guimarães

rodolfolabiapari@decom.ufop.br

Lattes: <http://goo.gl/MZv4Dc>

Departamento de Computação – Universidade Federal de Ouro Preto
Ouro Preto - MG – Brasil

Última Atualização: 28 de março de 2017.



[[Garcia and Delakis 2004]

]Garcia, C. and Delakis, M. (2004).

Convolutional face finder: A neural architecture for fast and robust face detection.

IEEE Transactions on Pattern Analysis and Machine Intelligence, 26(11):1408–1423.



[[Giusti et al. 2013]

]Giusti, A., Cireşan, D. C., Masci, J., Gambardella, L. M., and

Schmidhuber, J. (2013).

Fast image scanning with deep max-pooling convolutional neural networks.

In *2013 IEEE International Conference on Image Processing, ICIP 2013 - Proceedings*, pages 4034–4038.



[[Haoxiang and Lin 2015]

]Haoxiang, L. and Lin (2015).

A Convolutional Neural Network Approach for Face Identification.

IEEE Conference on Computer Vision and Pattern Recognition, pages 5325–5334.



[[Le Cun Jackel, B. Boser, J. S. Denker, D. Henderson, R. E. Howard, W. Hubbard et al.

1990]]Le Cun Jackel, B. Boser, J. S. Denker, D. Henderson, R. E. Howard, W.

Hubbard, L. D., Cun, B. L., Denker, J., and Henderson, D. (1990).

Handwritten Digit Recognition with a Back-Propagation Network.

Advances in Neural Information Processing Systems, pages 396–404.



[[LeCun 1989]

]LeCun, Y. (1989).

Generalization and network design strategies.



[[LeCun et al. 1998]

]LeCun, Y., Bottou, L., Bengio, Y., and Haffner, P. (1998).

Gradient-based learning applied to document recognition.

Proceedings of the IEEE, 86(11):2278–2323.

Processamento Digital de Imagem

Problema de Detecção Facial utilizando RCNN

Rodolfo Labiapari Mansur Guimarães

rodolfolabiapari@decom.ufop.br

Lattes: <http://goo.gl/MZv4Dc>

Departamento de Computação – Universidade Federal de Ouro Preto
Ouro Preto - MG – Brasil

Última Atualização: 28 de março de 2017.








Figura 13: Exemplo de processamento de reconhecimento de face no qual não obteve sucesso total na detecção de todas as faces. Resultado com Falso Positivos, no emblema, na bandeira e na cortina.




Figura 14: Processamento de reconhecimento de face no qual não obteve sucesso total na detecção de todas as faces. Resultado com Falso Positivos, na gravata, no terno e no microfone.

